

SIPATURE: Sistem Pemantauan Ulasan dan Prioritas Tindak Lanjut Pariwisata Toba

Laporan Analisis *Preliminary Round* — Del AI Hackathon 2026

Nama Tim : Kinderjoy (kadang minder tapi enjoy 🍌🍌🍌)
Ketua Tim : Jody Edriano Pangaribuan
Anggota 1 : Felix Nathanael Butar-butar
Anggota 2 : Daniel Haganta Ginting

Ringkasan. Ulasan wisata menyimpan informasi yang lebih rinci daripada *rating*. Sebuah tempat dapat memperoleh *rating* tinggi, tetapi masih memiliki laporan tentang toilet kotor, jalan rusak, pungutan, parkir, sampah, atau pelayanan. Ketika jumlah ulasan bertambah, pengelola sulit membaca semuanya secara rutin dan menentukan masalah mana yang perlu diperiksa lebih dahulu. SIPATURE dirancang sebagai *dashboard* dan sistem pendukung keputusan. Sistem membaca ulasan, mengelompokkan isu ke dalam 14 aspek, menunjukkan kutipan bukti, lalu membantu pengelola menyusun prioritas verifikasi. SIPATURE tidak menyatakan bahwa keluhan pasti benar dan tidak menggantikan pemeriksaan lapangan. *Pipeline* saat ini berhasil mengolah 22.302 *record* mentah menjadi 22.169 *record* bersih. Dari jumlah tersebut, 12.234 memiliki teks dan 9.935 hanya memiliki *rating*. Sebanyak 1.320 *review* berteks dipilih secara terstruktur untuk membuat label bantu atau *silver labels*. Label ini digunakan untuk membangun *baseline Keyword* dan TF-IDF serta melatih kandidat IndoBERT pada pembagian data yang aman dari kebocoran destinasi. Pada *locked silver test*, *Keyword* memperoleh *Macro F1* 0,9768 dan TF-IDF memperoleh 0,7201. Nilai ini hanya mengukur kesesuaian terhadap *silver labels*, bukan akurasi terhadap label manusia. Skor *Keyword* sangat tinggi karena memakai kosakata *taxonomy* yang juga berkaitan dengan proses pembentukan *silver labels*. Oleh karena itu, hasil tersebut diperlakukan sebagai batas pembanding, bukan bukti bahwa model telah memahami kondisi nyata. Kandidat IndoBERT dilatih menggunakan *train/validation*, lalu suhu dan *threshold* dibekukan hanya dari *validation*. Pada satu evaluasi *locked silver test*, deteksi aspek IndoBERT memperoleh *Macro F1* 0,5247, di bawah TF-IDF 0,7201, sedangkan klasifikasi *polarity* berbasis aspek memperoleh *Macro F1* 0,7459. Karena itu, TF-IDF dipertahankan sebagai kandidat detektor aspek yang belajar dari data, sedangkan IndoBERT *polarity* dipertimbangkan sebagai tugas terpisah. Model *severity* tidak dipaksakan karena kelas *high* hanya memiliki 19 contoh *train*, di bawah batas metodologis minimum 20.

Kata Kunci: Ulasan pariwisata, analisis berbasis aspek, TF-IDF, IndoBERT, sistem pendukung keputusan.

DAFTAR ISI

1. Latar Belakang	4
1.1. Konteks Pariwisata Toba	4
1.2. Potensi dan Tantangan Dataset	4
1.3. Kesenjangan Informasi dalam Pengelolaan Ulasan	4
1.4. Gagasan Solusi SIPATURE	5
1.5. Tujuan dan Manfaat	5
1.6. Ruang Lingkup dan Batasan Awal	5
2. Analisis Permasalahan	6
2.1. Temuan Utama Data	6
2.1.1 Skala dan Komposisi Data	6
2.1.2 Ketersediaan Teks dan Distribusi <i>Rating</i>	7
2.1.3 Dataset Sumber dan Perannya	8
2.1.4 Integrasi, Pembersihan, dan Penghubungan Entitas	9
2.2. Kelengkapan dan Potensi Geospasial	11
2.3. Hubungan Volume <i>Review</i> dan Sinyal Keluhan	13
2.4. Masalah yang Dipilih	14
2.5. Risiko yang Harus Diatasi	15
3. Desain dan Indikator Keberhasilan Solusi	16
3.1. Cara Kerja SIPATURE	16
3.2. Fitur Utama	16
3.2.1 Implementasi Antarmuka Preliminary	17
3.3. Diferensiasi	18
3.4. Indikator Keberhasilan	19
4. Perencanaan Implementasi	20
4.1. Alur Implementasi	20
4.2. Kapan Seluruh Data Digunakan	20
4.3. Rencana Implementasi pada <i>Final Round</i>	21
5. <i>Modelling</i>	23
5.1. Persiapan Data	23
5.2. Contoh Perubahan Bentuk Data	24
5.2.1 Bentuk Awal: CSV	24
5.2.2 Setelah <i>Cleaning</i> dan <i>Entity Resolution</i> : Parquet	25
5.2.3 Setelah <i>Annotation</i> : JSONL	25
5.2.4 Bentuk <i>Output</i> Inferensi dan Proyeksi Aplikasi	26
5.3. Mengapa Hanya 1.320 <i>Review</i> yang Berlabel	27
5.4. <i>Leakage-Safe Split</i>	28
5.5. <i>Baseline Keyword</i>	28
5.6. <i>Baseline TF-IDF</i>	28
5.7. Pelatihan Kandidat IndoBERT	29

6.	Evaluasi Model.....	32
6.1.	Protokol.....	32
6.2.	Evaluasi Model	32
6.3.	<i>Calibration, Alert, dan Polarity</i>	33
7.	Hasil dan Pembahasan	35
7.1.	Hasil yang Sudah Tersedia.....	35
7.2.	Apa yang Belum Boleh Diklaim.....	35
7.3.	Hubungan Model dengan Produk	36
7.4.	Dampak yang Diharapkan	36
8.	Deklarasi Penggunaan AI	38

1. Latar Belakang

Bagian ini menjelaskan konteks pariwisata Toba, potensi dan tantangan dataset, kesenjangan dalam pengelolaan ulasan, serta alasan pengembangan SIPATURE. Selain itu, bagian ini merangkum tujuan, manfaat, ruang lingkup, dan batasan awal solusi sebagai dasar bagi analisis pada bagian berikutnya.

1.1. Konteks Pariwisata Toba

Kawasan Danau Toba memiliki ekosistem pariwisata yang saling bergantung. Pengalaman wisatawan tidak hanya ditentukan oleh daya tarik sebuah destinasi, tetapi juga oleh kebersihan, akses jalan, parkir, toilet, keamanan, harga, pelayanan, akomodasi, kuliner, transportasi, dan informasi operasional. Masalah pada salah satu unsur tersebut dapat memengaruhi kenyamanan pengunjung dan citra kawasan secara keseluruhan.

Peningkatan kualitas pariwisata membutuhkan informasi yang dapat digunakan untuk mengambil tindakan. Pengelola perlu mengetahui bukan hanya tempat mana yang populer, tetapi juga masalah apa yang berulang, seberapa banyak bukti yang tersedia, dan hal apa yang perlu diperiksa lebih dahulu. Informasi tersebut penting agar sumber daya yang terbatas dapat diarahkan pada kebutuhan yang paling relevan.

1.2. Potensi dan Tantangan Dataset

Dataset yang disediakan mencakup objek wisata, akomodasi, kuliner, transportasi, fasilitas, lokasi, harga, jam operasional, *rating*, dan ulasan pengguna. Cakupan ini memungkinkan analisis pariwisata dilakukan sebagai satu ekosistem, bukan sebagai daftar destinasi yang berdiri sendiri. Ulasan pengguna menjadi komponen penting karena memuat pengalaman langsung yang tidak selalu tercermin pada *metadata* atau *rating* rata-rata.

Namun, data tersebut masih mentah dan realistis. Informasi tersebar di sejumlah file dengan struktur yang berbeda, beberapa nama tempat tidak konsisten, sebagian *field* kosong, dan tidak semua *review* memiliki teks. Tempat yang sama juga dapat muncul dengan variasi nama pada sumber review dan *metadata*. Oleh sebab itu, data tidak dapat langsung dimasukkan ke model. Diperlukan pemeriksaan kualitas, pembersihan, penyamaan struktur, penghubungan entitas, dan dokumentasi perubahan data sebelum analisis dilakukan.

Kondisi ini sejalan dengan tujuan Del AI Hackathon 2026, yaitu memanfaatkan dataset utama panitia secara bermakna dan mengubah data pariwisata yang belum terintegrasi menjadi *insight*, layanan, atau sistem pendukung keputusan. SIPATURE menggabungkan ruang eksplorasi **operasional destinasi** dan **data intelligence**. NLP (*Natural Language Processing*) digunakan sebagai pendekatan AI utama untuk memahami isi ulasan, sedangkan hasil analisis disajikan dalam bentuk **Dashboard & Decision support** bagi pengelola.

1.3. Kesenjangan Informasi dalam Pengelolaan Ulasan

Rating rata-rata memberikan gambaran umum, tetapi tidak menjelaskan penyebab pengalaman pengunjung. Dua destinasi dengan *rating* yang sama dapat menghadapi masalah yang berbeda. Satu tempat mungkin memiliki keluhan mengenai toilet dan sampah, sedangkan tempat lain menghadapi masalah akses, parkir, pelayanan, atau transparansi harga. Bahkan *review* dengan *rating* tinggi dapat tetap mengandung kritik pada aspek tertentu.

Membaca ulasan satu per satu juga tidak efisien ketika jumlahnya mencapai ribuan. Keluhan penting dapat tertutup oleh *review* positif, komentar singkat, atau tempat yang mempunyai volume ulasan lebih besar. Jika pengelola hanya melihat jumlah keluhan mentah, destinasi populer berisiko selalu terlihat paling bermasalah karena memiliki lebih banyak *review*. Sebaliknya, persentase keluhan yang tinggi pada tempat dengan sedikit *review* dapat terlihat terlalu ekstrem dan belum tentu stabil.

Dengan demikian, kebutuhan utamanya bukan sekadar analisis sentimen positif dan negatif. Pengelola memerlukan sistem yang dapat mengidentifikasi **aspek yang dibicarakan**, menunjukkan **potongan bukti dari review**, memperhitungkan **jumlah dan kecukupan data**, serta menyusun **prioritas verifikasi** tanpa menyatakan keluhan pengguna sebagai fakta lapangan.

1.4. Gagasan Solusi SIPATURE

SIPATURE merupakan singkatan dari **Sistem Pemantauan Ulasan dan Prioritas Tindak Lanjut Pariwisata Toba**. Nama ini juga memiliki kedekatan dengan nilai budaya Batak. Secara kontekstual, kata *pature* mengandung makna membenahi, menata, atau memperbaiki, sedangkan *sipature* dapat dimaknai sebagai pihak yang membenahi. Semangat tersebut selaras dengan ungkapan Batak *Marsipature Huta Na Be*, yaitu ajakan untuk bersama-sama membangun dan memperbaiki kampung halaman masing-masing. Dalam SIPATURE, semangat itu diwujudkan melalui pemanfaatan suara pengunjung untuk membantu pengelola mengenali hal yang perlu diperiksa dan dibenahi demi peningkatan kualitas pariwisata Toba. Dengan demikian, nama SIPATURE tidak hanya berfungsi sebagai akronim teknis, tetapi juga membawa pesan lokal tentang kepedulian, gotong royong, dan tanggung jawab merawat kawasan Toba.

Solusi ini dirancang sebagai *dashboard* dan sistem pendukung keputusan yang mengubah *review* menjadi sinyal operasional per destinasi. Model membaca teks *review*, mengelompokkan pembahasan ke dalam 14 aspek, menentukan arah penilaian per aspek, menilai tingkat dampak untuk keluhan negatif, dan mempertahankan kutipan *evidence* yang dapat diperiksa.

Hasil per *review* kemudian diringkas pada tingkat destinasi dengan mempertimbangkan volume bukti, *severity*, *freshness*, dan kecukupan data. Destinasi dengan data sedikit tidak otomatis diberi penilaian baik atau buruk, tetapi ditandai sebagai *Insufficient Data*. Sinyal prioritas juga tetap berstatus belum terverifikasi sampai pengelola melakukan pemeriksaan. Dengan pendekatan ini, SIPATURE berfungsi sebagai alat penyaring dan pemberi arah awal, bukan sebagai pengganti inspeksi lapangan atau keputusan manusia.

Pengguna utama SIPATURE adalah pengelola destinasi yang perlu memantau keluhan dan menentukan pemeriksaan operasional. Pemerintah daerah atau pengelola kawasan menjadi pengguna sekunder untuk melihat pola lintas destinasi. Dalam pengembangan berikutnya, hasil agregat juga dapat membantu penyusunan program perbaikan fasilitas, koordinasi dengan pelaku layanan pendukung, dan evaluasi perubahan kondisi dari waktu ke waktu.

1.5. Tujuan dan Manfaat

Tujuan pengembangan SIPATURE adalah:

1. Mengintegrasikan *review* dan *metadata* pariwisata Toba ke dalam struktur data yang dapat ditelusuri.
2. Mengidentifikasi aspek pengalaman wisatawan secara lebih spesifik daripada sentimen umum.
3. Menyediakan *evidence* anonim agar hasil model dapat diperiksa kembali.
4. Membedakan sinyal yang memiliki dukungan memadai dari kondisi yang datanya belum cukup.
5. Membantu pengelola menyusun urutan verifikasi secara lebih cepat dan transparan.
6. Menyediakan fondasi data dan model yang dapat dikembangkan menjadi produk pada *Final Round*.

Manfaat yang diharapkan bagi pengelola adalah berkurangnya waktu untuk membaca *review* secara manual, meningkatnya kemampuan menemukan isu berulang, dan tersedianya dasar yang lebih jelas untuk menentukan tindak lanjut. Bagi pemerintah atau pengelola kawasan, SIPATURE dapat memberikan gambaran lintas destinasi dengan tetap mempertahankan konteks *evidence* dan keterbatasan data. Bagi wisatawan dan pelaku lokal, tindak lanjut yang lebih terarah diharapkan berkontribusi pada pengalaman wisata yang lebih aman, nyaman, informatif, dan berkelanjutan.

1.6. Ruang Lingkup dan Batasan Awal

Ruang lingkup *preliminary* berfokus pada pengolahan dataset panitia, pengembangan *taxonomy* aspek, pembuatan *silver labels*, pembangunan *baseline Keyword* dan *TF-IDF*, evaluasi *leakage-safe*, serta rancangan integrasi model dengan *dashboard*. Analisis utama menggunakan *review* berteks, sedangkan *rating-only* digunakan sebagai konteks volume, distribusi *rating*, dan kecukupan data. *Metadata* lokasi digunakan untuk menghubungkan *review* dengan destinasi dan mendukung penyajian geospasial.

SIPATURE tidak menilai kebenaran faktual sebuah keluhan, tidak menentukan sanksi, dan tidak mempublikasikan identitas *reviewer*. *Silver labels* yang digunakan pada tahap awal bukan *human-gold labels*, sehingga hasil evaluasi belum dapat disebut sebagai akurasi terhadap penilaian manusia. Selain itu, keterbatasan *metadata* tidak boleh ditafsirkan sebagai bukti bahwa fasilitas atau layanan tidak tersedia di dunia nyata. Batasan tersebut dijaga agar solusi tetap transparan, etis, dan dapat dipertanggungjawabkan.

2. Analisis Permasalahan


Bagian ini membahas kondisi dan karakteristik utama dataset pariwisata Toba sebagai dasar perumusan masalah SIPATURE. Pembahasan mencakup skala dan kualitas data, proses integrasi, kelengkapan metadata, potensi geospasial, hubungan volume ulasan dengan sinyal keluhan, masalah yang dipilih, serta risiko yang perlu dimitigasi.

2.1. Temuan Utama Data

Bagian ini menyajikan hasil pemeriksaan awal terhadap skala, komposisi, ketersediaan informasi, sumber, dan proses integrasi data. Pembahasan dibagi menjadi beberapa subbagian agar hubungan antara temuan, tabel, dan visual dapat diikuti secara lebih sistematis.

2.1.1 Skala dan Komposisi Data

Tim memeriksa dan mengolah 14 *file* CSV yang disediakan panitia. Seluruh file berhasil dibaca tanpa kesalahan, kemudian diperiksa struktur kolom, jumlah baris, kelengkapan nilai, dan perannya dalam proses analisis. Dua file ulasan utama berisi total 22.302 *record*. Setelah tahap pembersihan dan penghubungan data, diperoleh 22.169 *record* bersih yang seluruhnya memiliki “*destination_id*” teknis.



Gambar 2. 1 Ukuran *file* berdasarkan jumlah *record*.

Dua batang terpanjang adalah *file* ulasan wisata dan ulasan restoran/hotel, masing-masing 12.691 dan 9.611 *record*. *File* lainnya jauh lebih kecil karena terutama berisi *metadata*, jam operasional, transportasi, atau informasi pendukung. Visual ini menunjukkan bahwa kekuatan utama dataset berada pada ulasan, sedangkan file kecil digunakan untuk memperkaya konteks tempat.


Tabel 2. 1 Ringkasan hasil pemeriksaan dan pembersihan data

Temuan	Nilai	Implikasi
Record mentah	22.302	Volume terlalu besar untuk dibaca manual secara rutin

Temuan	Nilai	Implikasi
<i>Record</i> bersih	22.169	Menjadi dasar integrasi dan agregasi
<i>Review</i> berteks	12.234	Dapat dianalisis dengan NLP
Rating-only	9.935	Berguna sebagai konteks, tetapi tidak menjelaskan aspek
<i>Rating</i> bintang lima	15.595 dari 22.243 <i>rating integer</i>	Data sangat condong ke <i>rating</i> tinggi
<i>Canonical</i> IDs teknis	388	322 metadata anchors dan 66 unresolved placeholders

Dataset memiliki volume *review* yang besar, tetapi hanya sekitar separuh *record* yang mempunyai teks. Karena model NLP memerlukan teks, *review rating-only* dipisahkan untuk konteks agregasi. Dominasi *rating* bintang lima dan keberadaan *unresolved placeholders* juga menunjukkan bahwa sistem perlu memperhitungkan ketidakseimbangan serta ketidakpastian data.


2.1.2 Ketersediaan Teks dan Distribusi *Rating*



Gambar 2. 2 Ketersediaan informasi pada data mentah.

Dari 22.302 *record*, hampir semua memiliki *rating*, tetapi hanya 12.280 yang memiliki teks sebelum *cleaning*. Sebanyak 9.978 *record* hanya memiliki *rating* dan 83 merupakan duplikat fisik berlebih. Setelah *cleaning* yang lebih ketat, angka yang digunakan *pipeline* menjadi 12.234 *review* berteks dan 9.935 *rating-only*. Perbedaan angka sebelum dan sesudah *cleaning* menunjukkan bahwa data perlu diperiksa sebelum dipakai oleh model.

Rating tinggi tidak selalu berarti tidak ada masalah. Karena itu, SIPATURE membaca isi ulasan dan tidak menggunakan *rating* untuk menentukan *polarity* atau *severity* sebuah aspek.



Gambar 2. 3 Distribusi *rating* pada data mentah.

Batang bintang lima jauh lebih tinggi daripada *rating* lain. Artinya, model yang hanya mengikuti kelas mayoritas dapat terlihat baik, padahal belum tentu menemukan keluhan penting. Karena itu SIPATURE membaca teks dan menggunakan *Macro F1* agar aspek yang jarang tetap diperhatikan.

2.1.3 Dataset Sumber dan Perannya

Dataset dari panitia tidak diperlakukan sebagai satu tabel besar yang langsung digabung. Setiap jenis file memiliki makna berbeda, sehingga dibaca dengan aturan yang sesuai sebelum dipertemukan melalui nama tempat, kategori, alamat, dan koordinat.

Tabel 2. 2 Daftar dataset sumber dan perannya dalam *pipeline*

Kelompok	Nama file CSV sumber	Peran dalam <i>pipeline</i>
Review wisata	wisata-v2.csv	Sumber ulasan dan <i>rating</i> objek wisata
Review hotel/restoran	resto-hotel-v2.csv	Sumber ulasan dan <i>rating</i> hotel/restoran
Metadata wisata	wisata-metadata.csv	Nama, kategori, alamat, koordinat, status, <i>rating</i>
Metadata restoran	resto-metadata.csv	Nama, koordinat, <i>rating</i> , harga, fasilitas, status
Metadata hotel	hotel-metadata.csv	Nama, koordinat, <i>rating</i> , harga, fasilitas, status
Data tempat wisata	tempat-wisata-v1.csv	Fasilitas, <i>review</i> , dan status tambahan dan tidak seragam

Kelompok	Nama <i>file</i> CSV sumber	Peran dalam <i>pipeline</i>
Jam operasional	waktu operasional destinasi.csv	<i>Enrichment</i> jam dan fasilitas destinasi
Transportasi	transportasi.csv	Rute, tarif, dan jadwal transportasi
Data kawasan	Info Seputar Danau Toba (TOP 3).csv	Informasi ekosistem wilayah yang lebar
Atraksi tambahan	Attractions Info.csv	Deskripsi atraksi, lokasi, jam, tiket, budaya
Hotel/restoran pendukung	hotel-resto-v1.csv	Daftar tempat pendukung dengan <i>field</i> heterogen
Kuliner	kuliner.csv	Deskripsi kuliner
Artikel kawasan	Artikel Danau Toba.csv	Konteks artikel, bukan label model

Dua *file review* menjadi sumber utama analisis bahasa. Tiga *file metadata* utama menyediakan identitas dan lokasi tempat. File lainnya berfungsi sebagai *enrichment* atau konteks tambahan dan tidak seluruhnya menjadi label model. Pemisahan peran ini mencegah artikel atau *field* pendukung diperlakukan sebagai *ground truth* secara keliru.

2.1.4 Integrasi, Pembersihan, dan Penghubungan Entitas

Proses penggabungan dilakukan bertahap sebagaimana diringkaskan pada Tabel 2.3.

Tabel 2. 3 Tahapan integrasi dataset SIPATURE


Tahap integrasi	Dataset masukan	Proses utama	Keluaran
Standardisasi <i>review</i>	wisata-v2.csv, resto-hotel-v2.csv	Menyamakan nama kolom, normalisasi teks/ <i>rating</i> , membentuk ID dan status <i>review</i>	Tabel <i>review</i> : review_id, nama tempat, teks, <i>rating</i> , dan tanggal
Standardisasi <i>metadata</i>	wisata-metadata.csv, resto-metadata.csv, hotel-metadata.csv	Menyamakan nama, kategori, alamat, koordinat, harga, fasilitas, dan status	Tabel <i>metadata</i> tempat
Enrichment	tempat-wisata-v1.csv, waktu operasional destinasi.csv, transportasi.csv, dan file pendukung	Menata jam operasional, fasilitas, rute, tarif, serta konteks kawasan	Tabel <i>enrichment</i> terstruktur
Entity resolution	Tabel review, metadata, dan enrichment	Membandingkan nama, jenis, alamat, serta koordinat secara konservatif	Hubungan <i>review</i> –destinasi dan daftar kandidat tidak pasti

Tahap integrasi	Dataset masukan	Proses utama	Keluaran
Pembentukan data <i>canonical</i>	Hasil entity resolution	Menetapkan ID utama dan <i>unresolved placeholder</i> bila kecocokan belum pasti	<i>canonical_reviews.parquet</i> dan <i>canonical_destinations.parquet</i>

Integrasi tidak dilakukan dengan menumpuk seluruh CSV sekaligus karena struktur dan makna *field* berbeda. *Review* terlebih dahulu distandardisasi, *metadata* tempat dibentuk secara terpisah, dan file pendukung dijadikan *enrichment*. Ketiga kelompok baru dipertemukan melalui *entity resolution*. Pendekatan ini mengurangi risiko salah mengartikan kolom atau menggabungkan dua tempat yang berbeda.

Setelah standardisasi struktur pada Tabel 2.3, proses dilanjutkan melalui dua tahap yang berbeda. Tahap pertama membersihkan baris *review* dan menentukan data yang layak dipertahankan. Tahap kedua menghubungkan nama tempat dari berbagai sumber dengan identitas destinasi yang konsisten. Pemisahan ini penting karena Gambar 2.4 menggunakan satuan jumlah *review*, sedangkan Gambar menggunakan satuan jumlah hubungan entitas tempat.

Tahap 1: Pembersihan dan Pemisahan Data Review



Gambar 2. 4 Alur pembersihan dan pemisahan data *review*.

Proses dimulai dari 22.302 *record* mentah. Sebanyak 89 baris duplikat teknis berlebih dan 44 baris tanpa *rating* maupun teks dikeluarkan, sehingga tersisa 22.169 *record* bersih. Dari data bersih tersebut, 12.234 *record* memiliki teks dan dapat digunakan untuk analisis NLP, sedangkan 9.935 lainnya hanya memiliki *rating* dan tetap dipertahankan sebagai konteks agregasi.

Batang “*Clean textual*” pada Gambar 2.2 bukan tahap penghapusan lanjutan dari 22.169 *record* bersih, melainkan subset dari data bersih yang mempunyai teks. Dengan demikian, hubungan angkanya adalah 22.302 data mentah dikurangi 89 duplikat dan 44 data kosong menjadi 22.169 data bersih; selanjutnya, 22.169 data bersih dipisahkan menjadi 12.234 *review* berteks dan 9.935 *rating-only records*. Data yang dikeluarkan tetap dicatat pada artefak audit agar proses pembersihan dapat ditelusuri.


Tahap 2: Penghubungan Identitas Tempat

Setelah data *review* bersih tersedia, nama tempat pada file *review*, *metadata*, dan sumber pendukung dibandingkan melalui *entity resolution*. Pada tahap ini, unit yang dihitung bukan lagi jumlah *review*, melainkan **810 hubungan kandidat antarsumber tempat**. Satu hubungan menunjukkan upaya menghubungkan satu penyebutan tempat dari suatu sumber dengan identitas destinasi yang menjadi acuan.

Tahap ini diimplementasikan menggunakan *Python* dan *Pandas* untuk normalisasi, pengelompokan, serta penggabungan data. Pustaka atau *Library RapidFuzz* digunakan untuk menghitung kemiripan nama dan alamat melalui metode *ratio* dan *token_set ratio*. Koordinat dibandingkan menggunakan rumus *Haversine* untuk mengukur jarak antarlokasi, sedangkan jenis tempat digunakan sebagai pembatas agar

objek wisata tidak dicocokkan dengan hotel atau restoran secara keliru. ID destinasi dibentuk secara deterministik menggunakan **SHA-256** agar hasil pengelompokan dapat direproduksi. Kandidat dengan kecocokan nama, alamat, jenis, atau koordinat yang belum cukup kuat dimasukkan ke pemeriksaan manual dan tidak digabungkan secara otomatis.

Status 810 Hubungan Entitas Tempat Setelah Pemeriksaan




Gambar 2. 5 Status 810 hubungan entitas tempat setelah pemeriksaan.

Sebanyak 698 hubungan dapat dicocokkan otomatis karena memiliki bukti yang kuat. Sebanyak 45 hubungan dikonfirmasi setelah pemeriksaan manusia, sedangkan 31 hubungan dikonfirmasi sebagai tidak cocok dan dipertahankan secara terpisah. Empat hubungan masih memerlukan pemeriksaan lebih lanjut, dan 32 hubungan belum dapat diselesaikan karena bukti yang tersedia belum cukup.

Hubungan yang belum cukup kuat tidak dipaksa bergabung. Sistem memberikan *unresolved placeholder*, yaitu ID sementara yang menjaga *review* tetap dapat dikelompokkan tanpa mengklaim bahwa dua penyebutan merujuk pada tempat yang sama. Status tidak cocok dan belum terselesaikan bukan berarti data dibuang. Jadi, keduanya merupakan mekanisme pengaman untuk mencegah penggabungan tempat yang salah.

2.2. Kelengkapan dan Potensi Geospasial


Analisis pada bagian ini bertujuan menilai apakah *metadata* tempat cukup lengkap untuk mendukung identifikasi destinasi, penyajian peta, dan analisis kedekatan layanan. Pemeriksaan dilakukan terhadap ketersediaan atribut penting, seperti nama, alamat, koordinat, kategori, fasilitas, dan jam operasional, kemudian dilanjutkan dengan melihat pola persebaran lokasi hotel, restoran, dan destinasi wisata.



Gambar 2. 6 Kelengkapan *metadata* hotel, restoran, dan wisata.

Warna gelap berarti *field* lebih lengkap. Nama, alamat, koordinat, dan status tersedia hampir penuh, sehingga cukup kuat untuk *linkage* dan peta. Sebaliknya, fasilitas hotel tersedia 83% tetapi fasilitas restoran hanya 4% dan wisata 0% pada file *metadata* utama; jam operasional juga tidak merata. SIPATURE tidak menganggap *field* kosong sebagai “tidak ada fasilitas”, melainkan sebagai data yang belum cukup.

Sebaran Koordinat Metadata Pariwisata




Gambar 2. 7 Sebaran latitude dan longitude pada 323 metadata records.

Latitude menunjukkan posisi utara–selatan, sedangkan longitude menunjukkan posisi timur–barat. Setiap titik mewakili hotel, restoran, atau destinasi wisata. Titik wisata tersebar lebih luas, sementara hotel dan restoran lebih mengelompok pada beberapa pusat layanan. Gambar ini menarik untuk solusi karena membuktikan bahwa data dapat dikembangkan menjadi peta persebaran destinasi, analisis kedekatan layanan, dan perbandingan kawasan. Plot ini menunjukkan koordinat, bukan jarak perjalanan atau batas administratif.

2.3. Hubungan Volume *Review* dan Sinyal Keluhan

Analisis berikut digunakan untuk melihat hubungan antara banyaknya *review* berteks dan proporsi ulasan yang mengandung kata kandidat keluhan pada setiap tempat. Tujuannya adalah menguji apakah persentase keluhan dapat langsung digunakan sebagai dasar prioritas atau perlu dibaca bersama jumlah bukti, distribusi *rating*, dan kecukupan data.



Gambar 2. 8 Hubungan jumlah *review* berteks dengan *candidate complaint rate*.

Setiap titik mewakili satu tempat. Semakin ke kanan posisi titik, semakin banyak *review* berteks yang tersedia. Semakin tinggi posisi titik, semakin besar proporsi *review* yang memuat kata kandidat keluhan. Warna titik menunjukkan *rating* rata-rata dan digunakan sebagai konteks tambahan, bukan sebagai penentu ada atau tidaknya keluhan.

Persentase yang tinggi belum selalu berarti sebuah tempat lebih bermasalah. Sebagai contoh, satu *review* kandidat keluhan dari dua *review* berteks menghasilkan persentase 50%, sedangkan 20 *review* kandidat keluhan dari 100 *review* berteks menghasilkan persentase 20%. Tempat pertama mempunyai persentase lebih tinggi, tetapi hanya didukung oleh satu komentar sehingga hasilnya lebih mudah berubah ketika *review* baru masuk. Sebaliknya, tempat kedua memiliki lebih banyak bukti meskipun persentasenya lebih rendah. Grafik juga tidak memperlihatkan hubungan sederhana bahwa *rating* tinggi selalu diikuti sinyal keluhan rendah, atau bahwa tempat dengan lebih banyak *review* selalu memiliki proporsi keluhan lebih besar.

Jumlah kandidat keluhan dan persentasenya harus dibaca secara bersama. Urutan pemantauan tidak dapat ditentukan hanya dari persentase mentah karena hasil pada tempat dengan sedikit *review* cenderung belum stabil. SIPATURE kemudian menggunakan jumlah dukungan, kecukupan data, dan *Bayesian smoothing* untuk mengurangi pengaruh nilai ekstrem akibat sampel kecil. Istilah *candidate complaint rate* pada grafik hanya menunjukkan pencarian awal menggunakan kata kandidat keluhan. Nilai tersebut bukan hasil klasifikasi model final, bukan ukuran jumlah pengunjung, dan bukan konfirmasi bahwa masalah benar-benar terjadi di lapangan.

2.4. Masalah yang Dipilih

Masalah utama dirumuskan sebagai berikut: Bagaimana membantu pengelola mengubah ribuan ulasan yang tersebar menjadi daftar isu yang spesifik, didukung oleh sinyal yang dapat ditelusuri, dan dapat diprioritaskan untuk verifikasi?

Sistem rekomendasi wisata tidak dipilih sebagai fokus utama karena dataset juga menyimpan peluang yang kuat untuk membantu pengelola. SIPATURE mengubah feedback pengunjung menjadi sinyal awal untuk tindakan, bukan hanya daftar tempat yang menarik.

2.5. Risiko yang Harus Diatasi

Tabel 2. 4 Risiko utama data, model, dan produk beserta mitigasinya

Risiko	Dampak	Mitigasi
<i>Rating</i> dan kelas tidak seimbang	Masalah langka dapat tertutup	Stratified sampling, Macro F1, dan class weighting
Nama tempat tidak konsisten	<i>Review</i> dapat terhubung ke tempat yang salah	Conservative entity resolution dan unresolved placeholder
Ulasan berulang	Model dapat menghafal teks	Pengelompokan duplikat dan teks berulang ketika membentuk <i>split</i>
<i>False alert</i>	Reputasi destinasi dapat dirugikan	Bahasa netral, <i>threshold</i> , dukungan agregat, artefak bukti terbatas, dan verifikasi manusia
Data sedikit atau usang	Skor terlihat lebih pasti daripada kenyataan	Data sufficiency, bobot freshness, dan status Insufficient Data
Silver labels mengandung bias rules	Evaluasi terlihat terlalu optimistis	Menyebut hasil sebagai <i>silver agreement</i> dan merencanakan <i>human-gold reference</i>
Teks ulasan terungkap (<i>exposed</i>)	Risiko privasi, atribusi, dan penyalahgunaan	Menampilkan agregat aman untuk privasi; teks dan artefak tingkat <i>reviewer</i> tetap terbatas
Rekomendasi dianggap keputusan otomatis	Tindakan dilakukan tanpa pemeriksaan lapangan	Menempatkan SIPATURE sebagai alat triase dan keputusan akhir tetap pada pengelola

Risiko terbesar bukan hanya kesalahan klasifikasi, tetapi juga salah menggabungkan destinasi, ketimpangan *support*, kebocoran teks ulasan, dan potensi kerugian reputasi akibat *false alert*. Karena itu, aplikasi tahap preliminary hanya memakai proyeksi agregat yang aman untuk privasi. Teks *evidence*, ID *review*, dan artefak tingkat *reviewer* dipertahankan untuk audit, tetapi belum ditampilkan sebelum pemeriksaan privasi dan ahli selesai.

3. Desain dan Indikator Keberhasilan Solusi

Bagian ini menjelaskan desain SIPATURE sebagai *dashboard* dan sistem pendukung keputusan yang mengubah ulasan menjadi sinyal operasional per destinasi. Pembahasan mencakup alur kerja sistem dari data hingga aplikasi, *taxonomy* aspek yang digunakan, fitur utama yang tersedia, perbedaan SIPATURE dari *dashboard* sentimen umum, serta indikator untuk membedakan keberhasilan teknis yang telah terukur dari dampak operasional yang masih memerlukan validasi ahli dan *pilot* pengguna.

3.1. Cara Kerja SIPATURE

Cara kerja SIPATURE terdiri atas tujuh langkah. Pertama, dataset panitia diperiksa, dibersihkan, dan distandardisasi. Kedua, *review* dihubungkan dengan *metadata* destinasi melalui *entity resolution* yang konservatif. Ketiga, detektor aspek TF-IDF yang telah dikunci membaca 12.234 *review* berteks. Keempat, arah *polarity* ditentukan menggunakan *fallback* leksikal dan komponen ini dinyatakan secara eksplisit sebagai aturan deterministik dan bukan model IndoBERT *final*. Kelima, hasil per *review* diagregasikan menjadi sinyal destinasi-aspek. Keenam, sistem menghitung kecukupan data dan prioritas verifikasi hanya dari komponen yang tersedia. Ketujuh, proyeksi agregat yang aman untuk privasi disajikan melalui *dashboard* agar pengelola dapat menentukan apa yang perlu diperiksa lebih dahulu.

Inferensi korpus penuh menghasilkan 9.785 prediksi aspek dan 1.682 sinyal destinasi-aspek. Dari 388 *canonical* ID, 322 memiliki acuan *metadata* dan koordinat yang dapat dipetakan. Setelah aturan kecukupan dan kelayakan operasional diterapkan, keluaran atau *output* aplikasi mencakup 103 destinasi dengan 210 isu atau kandidat intervensi yang dapat ditindaklanjuti. Sebanyak 66 *unresolved placeholders* tetap dapat diaudit, tetapi tidak dipetakan dan tidak diberi peringkat operasional.

Tabel 3. 1 *Taxonomy* aspek yang dianalisis SIPATURE

Kelompok	Aspek
Lingkungan	Kebersihan, sampah dan limbah, toilet dan sanitasi, serta kepadatan dan antrean
Infrastruktur	Akses dan kondisi rute, parkir, serta fasilitas publik dan aksesibilitas
Pengalaman pengunjung	Pemandangan, kenyamanan, keselamatan dan keamanan, serta harga dan transparansi pungutan
Operasional	Pelayanan petugas, perawatan dan kerusakan, serta jam operasional

Empat kelompok aspek memisahkan isu lingkungan, infrastruktur, pengalaman pengunjung, dan operasional. Pembagian ini membuat hasil lebih mudah dihubungkan dengan unit atau jenis tindakan yang relevan dibandingkan sentimen positif atau negatif secara umum. Sebagai contoh, keluhan toilet dapat diarahkan pada pemeriksaan sanitasi, sedangkan keluhan jalan dapat diarahkan pada pemeriksaan akses dan kondisi rute.

Satu *review* dapat membahas beberapa aspek. Setiap aspek dapat memiliki *polarity positive*, *negative*, atau *neutral*. Pada tahap preliminary ini, model *severity* tidak tersedia karena kelas *high* hanya memiliki 19 contoh *train*. *Facility gap* dan *feasibility* juga tidak tersedia. Ketiga komponen tersebut tidak diisi dengan nol atau nilai netral buatan, melainkan dinormalisasi keluar dari formula prioritas.


3.2. Fitur Utama

1. **Overview kualitas data.** Menampilkan jumlah *record* bersih, *review* berteks, cakupan destinasi, versi model, dan keterbatasan komponen analisis.
2. **Peta prioritas verifikasi.** Menampilkan 322 destinasi berkoordinat dengan bentuk dan warna yang membedakan tingkat prioritas, tanpa menganggap sinyal sebagai kondisi lapangan yang telah terbukti.
3. **Rapor destinasi.** Menjelaskan *support*, frekuensi keluhan, *data confidence*, aspek utama, komponen skor yang tersedia, dan rekomendasi verifikasi.

4. **Antrean verifikasi dan kandidat intervensi.** Menyajikan 210 isu pada 103 destinasi yang lolos aturan kelayakan operasional.
5. **Status *Insufficient Data*.** Membedakan data yang belum cukup dari kondisi yang benar-benar tidak memiliki isu terdeteksi.
6. **Simulasi skenario.** Memperlihatkan perubahan skor jika isu tertentu diasumsikan selesai, dengan penjelasan bahwa hasilnya bukan prediksi kausal.
7. **Analisis satu review.** Antarmuka langsung menggunakan *baseline* leksikal dan telah disiapkan sebagai titik integrasi model produksi berikutnya. Hasil input tidak mengubah data *dashboard*.
8. **Batas privasi yang eksplisit.** Aplikasi menampilkan dukungan dan sinyal agregat; kutipan teks, ID *review*, dan provenance tingkat *reviewer* belum dipublikasikan.

3.2.1 Implementasi Antarmuka Preliminary

Tiga tampilan berikut dipilih untuk mendokumentasikan aplikasi karena mewakili alur kerja utama SIPATURE: memantau kondisi secara regional, menentukan antrean verifikasi, kemudian memeriksa alasan dan tindak lanjut pada satu destinasi. Ketiganya juga menggunakan proyeksi agregat yang aman untuk privasi dan tidak menampilkan teks ulasan atau identitas *reviewer*.



Gambar 3. 1 Overview regional dan peta prioritas verifikasi SIPATURE.

Tampilan overview merangkum keluaran utama pipeline, yaitu 12.234 review berteks, 9.785 prediksi aspek, 103 destinasi actionable, dan 322 destinasi berkoordinat. Peta menghubungkan sinyal dengan lokasi, sedangkan panel kanan menunjukkan urutan awal destinasi untuk diperiksa. Filter nama tempat, kabupaten, jenis, aspek, dan status kecukupan data membantu pengelola mempersempit pemantauan. Warna dan peringkat pada tampilan ini merupakan sinyal prioritas verifikasi, bukan bukti bahwa kondisi lapangan telah dipastikan.

PRIORITAS VERIFIKASI LAPANGAN				
PRIORITAS	DESTINASI	SINYAL UTAMA	SUPPORT	LANGKAH BERIKUTNYA
#1 High	Elios - Rumah Makan Khas Batak Samosir - skor 72,8	Harga & Transparansi Pungutan	13 negatif / 17 sebutan evidence restricted	Periksa daftar harga, tiket, dan pungutan aktual. →
#2 High	Aek Rangat Pangururan Samosir - skor 72,5	Harga & Transparansi Pungutan	13 negatif / 19 sebutan evidence restricted	Periksa daftar harga, tiket, dan pungutan aktual. →
#3 High	Damasus Nataboan Resto Simalungun - skor 72,3	Pelayanan Petugas	24 negatif / 33 sebutan evidence restricted	Periksa SOP layanan dan respons petugas. →
#4 High	Kawah Putih Dolok Tinggi Raja Simalungun - skor 72,1	Harga & Transparansi Pungutan	14 negatif / 17 sebutan evidence restricted	Periksa daftar harga, tiket, dan pungutan aktual. →
#5 High	Sinar Minang Restaurant & Convention Hall Toba - skor 70,4	Harga & Transparansi Pungutan	7 negatif / 10 sebutan evidence restricted	Periksa daftar harga, tiket, dan pungutan aktual. →
#6 High	Tuan Nagani Paradise Humbang Hasundutan - skor 70,2	Harga & Transparansi Pungutan	8 negatif / 12 sebutan evidence restricted	Periksa daftar harga, tiket, dan pungutan aktual. →
#7 High	Rumah Makan Lomak Samosir - skor 70,1	Harga & Transparansi Pungutan	16 negatif / 31 sebutan evidence restricted	Periksa daftar harga, tiket, dan pungutan aktual. →
#8 High	Rumah Makan Muslim Penganapan Samosir - skor 69,9	Harga & Transparansi Pungutan	3 negatif / 4 sebutan evidence restricted	Periksa daftar harga, tiket, dan pungutan aktual. →
#9 High	LA PINUS DAMASUS BISTRO & RESTO Simalungun - skor 69,5	Pelayanan Petugas	11 negatif / 20 sebutan evidence restricted	Periksa SOP layanan dan respons petugas. →

Gambar 3. 2 Antrean verifikasi dan kandidat langkah tindak lanjut.

Tampilan antrean menerjemahkan skor agregat menjadi daftar kerja yang lebih operasional. Setiap baris memperlihatkan destinasi, aspek utama, jumlah dukungan negatif dibandingkan seluruh sebutan aspek, serta langkah verifikasi berikutnya. Penyajian tersebut membantu pengelola memahami alasan sebuah destinasi berada pada urutan tertentu tanpa membuka teks ulasan mentah. Label *evidence restricted* menegaskan bahwa kutipan pendukung masih ditahan sampai pemeriksaan privasi dan hak akses selesai; rekomendasi yang ditampilkan tetap harus dinilai manusia.

3.3. Diferensiasi

Tabel 3. 2 Perbedaan SIPATURE dengan *dashboard* sentimen umum

<i>Dashboard</i> sentimen umum	SIPATURE
Menampilkan positif/negatif secara umum	Memisahkan ulasan ke dalam 14 aspek yang lebih operasional
Berfokus pada <i>rating</i> atau jumlah sentimen	Menampilkan <i>support</i> , sinyal agregat, komponen skor, dan <i>data confidence</i>
Keluhan dapat terlihat sebagai fakta	Menggunakan bahasa “dilaporkan” dan meminta verifikasi lapangan
Semua tempat dapat terlihat sebanding	Menandai data yang belum cukup dan tidak meranking destinasi <i>unresolved</i>
Teks ulasan dapat tampil tanpa pembatasan	Menahan teks dan artefak tingkat <i>reviewer</i> sampai pemeriksaan privasi selesai

Nilai tambah SIPATURE terletak pada pemisahan isu per aspek, dukungan agregat, kecukupan data, dan bahasa verifikasi yang tidak menghakimi destinasi. Artefak teks yang mendasari sinyal dipertahankan untuk audit terkontrol, tetapi belum dipublikasikan. Dengan demikian, transparansi model tetap dijaga tanpa mengorbankan batas privasi pada produk preliminary ini.

3.4. Indikator Keberhasilan

Tabel 3. 3 Indikator keberhasilan dan hasil yang telah terukur

Lapisan	Indikator	Hasil yang sudah terukur
Data	Seluruh <i>clean review</i> memiliki <i>destination_id</i>	Tercapai: 22.169/22.169
<i>Split</i>	Tidak ada <i>destination/duplicate/repeated-text leakage</i>	Tercapai pada audit <i>leakage-safe split</i>
Model	<i>Macro</i> dan <i>Micro F1</i> pada <i>split</i> yang sama	Tersedia terhadap <i>silver labels</i> untuk Keyword, TF-IDF, dan IndoBERT
Inferensi korpus penuh	Seluruh <i>review</i> berteks diproses	12.234 <i>review</i> ; 9.785 prediksi aspek; 1.682 sinyal destinasi-aspek
Cakupan operasional	Destinasi dan isu yang lolos aturan kelayakan	103 destinasi dan 210 isu/kandidat intervensi
Integrasi produk	Proyeksi agregat tersedia pada aplikasi	Tercapai; <i>overview</i> , peta, rapor, antrean, simulator, dan analyzer tersedia
<i>Evidence</i>	Kutipan sesuai dengan sumber dan aman ditampilkan	Schema menjamin span sumber; audit manusia dan pemeriksaan privasi belum selesai
<i>Early warning</i>	Presisi terhadap penilaian ahli	Belum tersedia; 25 kasus telah disiapkan dan belum dinilai
Dampak pengguna	Relevansi prioritas dan waktu kerja	Belum diuji bersama pengelola

Fondasi data, evaluasi model, inferensi korpus, dan integrasi teknis aplikasi telah selesai. Namun, keberhasilan teknis tidak disamakan dengan dampak operasional. Ketepatan *early warning*, kualitas *evidence*, relevansi intervensi, kesesuaian peringkat, dan penghematan waktu tetap memerlukan penilaian ahli serta *pilot* bersama pengguna.

4. Perencanaan Implementasi

Bagian ini menjelaskan tahapan implementasi SIPATURE dari hasil preliminary menuju produk yang lebih utuh. Pembahasan mencakup status setiap komponen yang telah dibangun, penggunaan data pada tahap pelatihan hingga aplikasi, rencana *pilot* bersama pengelola, kebutuhan sumber daya dan tata kelola untuk keberlanjutan sistem, serta pekerjaan yang diprioritaskan pada *Final Round* beserta keluaran dan kriteria penyelesaiannya.

4.1. Alur Implementasi

Implementasi dimulai dari fondasi data: inventory, pemeriksaan kualitas, *cleaning*, dan penghubungan *review* ke destinasi. Setelah fondasi tersebut stabil, *taxonomy* dan *silver labels* dibuat untuk membangun *benchmark* awal. *Keyword* dan TF-IDF kemudian dibandingkan pada *split* yang sama dan bebas dari kebocoran yang terdeteksi.

Detektor aspek TF-IDF dibekukan setelah evaluasi dan telah dijalankan pada seluruh 12.234 *review* berteks. Hasilnya diagregasikan menjadi proyeksi aman untuk privasi dan diintegrasikan ke aplikasi SIPATURE. Pada proyeksi ini, *polarity* menggunakan *fallback* leksikal, bukan IndoBERT. Tahap berikutnya adalah pemeriksaan ahli terhadap 25 kasus yang telah disiapkan, pemeriksaan privasi *evidence*, pembentukan *human-gold reference*, dan *pilot* bersama pengelola untuk menilai apakah isu serta urutan prioritas benar-benar membantu pekerjaan mereka.

Tabel 3. 4 Status implementasi dari preliminary menuju produk utuh

Tahap	Status preliminary	Rencana pengembangan berikutnya
Fondasi data dan <i>entity resolution</i>	Selesai	Pembaruan data terjadwal dan audit <i>linkage</i> baru
Deteksi aspek TF-IDF	Selesai	Evaluasi ulang setelah tersedia <i>human-gold labels</i>
<i>Polarity</i>	<i>Fallback</i> leksikal	Integrasi model kontekstual
<i>Severity</i>	Tidak tersedia	Tambah anotasi kelas langka sebelum pelatihan ulang
Agregasi dan prioritas	Selesai	Validasi peringkat bersama pengelola
Aplikasi preliminary	Proyeksi agregat telah terintegrasi	Workflow status, autentikasi, audit log, dan monitoring
Kutipan <i>evidence</i>	Disimpan secara terbatas	Tampilkan hanya setelah pemeriksaan privasi dan hak akses
<i>Pilot</i> pengguna	Belum dilakukan	Meng-uji 5–10 destinasi dan bandingkan dengan proses manual

Produk preliminary telah membuktikan rantai dari data mentah hingga aplikasi, tetapi belum menutup seluruh kebutuhan operasional. Pengembangan berikutnya berfokus pada validasi manusia, keamanan akses, kualitas *polarity*, dan *workflow* tindak lanjut, bukan sekadar menambah jumlah fitur.

4.2. Kapan Seluruh Data Digunakan

Penggunaan data dibagi agar *training* dan evaluasi tidak bercampur dengan penggunaan produk:

1. **Saat *training*.** 922 *silver records* digunakan untuk melatih TF-IDF dan kandidat model lain.
2. **Saat memilih model.** 196 *validation records* digunakan untuk memilih *representation* dan *threshold*.
3. **Saat evaluasi.** 202 *locked-test records* digunakan setelah konfigurasi dibekukan.
4. **Saat inferensi korpus penuh.** TF-IDF terkunci dijalankan pada seluruh 12.234 *review* berteks dan menghasilkan 9.785 prediksi aspek.

5. **Saat agregasi aplikasi.** prediksi digabungkan dengan seluruh 22.169 *clean records* dan *metadata* destinasi menjadi 1.682 sinyal destinasi-aspek.
6. **Saat proyeksi produk.** hanya agregat yang aman untuk privasi digunakan aplikasi, menghasilkan 103 destinasi dan 210 isu yang dapat ditindaklanjuti.

Rating-only tidak dipaksa menjadi *input* NLP. Data tersebut digunakan untuk volume, distribusi *rating*, *coverage*, *visitor exposure*, dan *data sufficiency*. Pemisahan ini menjaga agar setiap jenis data dipakai sesuai informasi yang benar-benar dimilikinya dan mencegah *rating* dianggap sebagai label aspek atau *polarity*.

4.3. Rencana Implementasi pada *Final Round*

Pada *Final Round*, pengembangan tidak dimulai kembali dari nol. Fondasi data, model pembandingan, inferensi korpus, kontrak data, dan aplikasi preliminary dipertahankan sebagai dasar yang sudah dapat dijalankan. Pekerjaan final difokuskan pada penutupan kesenjangan yang paling memengaruhi keandalan produk, yaitu validasi manusia, keamanan *evidence*, integrasi model yang benar, dan alur tindak lanjut bagi pengelola.

Tabel 4. 1 Prioritas implementasi SIPATURE pada *Final Round*

Urutan	Fokus	Aktivitas	Keluaran	Kriteria selesai
1	Validasi ahli dan privasi	Menilai 25 kasus yang telah disiapkan, memeriksa dukungan kutipan, relevansi intervensi, risiko reputasi, dan PII	Hasil <i>expert review</i> , daftar kesalahan, dan keputusan akses <i>evidence</i>	Setiap kasus memiliki keputusan
2	Penetapan model final	Membandingkan TF-IDF terkunci dengan kandidat model kontekstual tanpa menyesuaikan model pada <i>locked test</i>	Model aspek dan <i>polarity</i> berversi beserta <i>threshold</i> dan <i>model card</i>	Model terpilih dapat dimuat ulang, memiliki metrik, versi, <i>hash</i> , dan keterbatasan yang terdokumentasi
3	Inferensi dan agregasi ulang	Menjalankan model terpilih pada korpus berteks, membentuk agregat, serta memvalidasi <i>schema</i> dan <i>hash</i>	Ekspor agregat baru yang dapat ditelusuri dan aman untuk aplikasi	Seluruh tahap lulus validasi
4	Integrasi model ke aplikasi	Menghubungkan ekspor <i>batch</i> dan endpoint analisis satu <i>review</i> melalui kontrak yang stabil	<i>Dashboard</i> memakai versi model final dan Analyzer memakai adapter final	Versi model, jenis skor, status komponen, <i>loading</i> , <i>error</i> , dan <i>empty state</i> tampil dengan benar
5	Workflow verifikasi	Menambahkan status <i>unverified</i> , <i>confirmed</i> , <i>rejected</i> , dan <i>uncertain</i> , catatan alasan, serta riwayat perubahan	Alur tindak lanjut yang dapat dipakai pengelola	Satu sinyal dapat ditinjau hingga keputusan tanpa mengubah prediksi sumber
6	Pengujian sistem dan UX	Menguji responsif, aksesibilitas, API, performa, privasi aset statis, <i>fallback</i>	Build yang stabil	<i>Typecheck</i> , <i>build</i> , <i>route test</i> , <i>privacy scan</i> , dan skenario demo utama lulus

Urutan	Fokus	Aktivitas	Keluaran	Kriteria selesai
7	Demo dan dokumentasi	peta, dan skenario tanpa internet Menyiapkan kasus utama, penjelasan model, batas klaim, panduan penggunaan, serta rencana <i>pilot</i>	Demo <i>end-to-end</i> dan dokumentasi yang konsisten dengan aplikasi	Narasi, angka, versi model, dan hasil pada laporan, slide, video, serta aplikasi selesai.

Urutan implementasi menempatkan validasi dan privasi sebelum membuka *evidence* atau mengganti model di aplikasi. Model yang lebih kompleks hanya digunakan jika memberi manfaat terukur dan dapat direproduksi; jika tidak, TF-IDF tetap menjadi pilihan. Integrasi Front End menggunakan kontrak respons yang stabil sehingga perubahan model tidak memerlukan perombakan halaman, sedangkan workflow verifikasi menyimpan keputusan manusia secara terpisah dari prediksi asli.

Fitur yang diprioritaskan pada *Final Round* adalah fitur yang memperkuat rantai *data* → *model* → *sinyal* → *verifikasi* → tindak lanjut. Pembatasan ruang lingkup ini menjaga agar waktu pengembangan digunakan untuk meningkatkan keandalan AI, keterlacakan hasil, keamanan data, dan kualitas pengalaman pengguna.


5. Modelling

Bagian ini menjelaskan proses pembangunan model SIPATURE mulai dari persiapan data hingga terbentuknya kandidat model yang dapat dievaluasi. Pembahasan mencakup pembersihan dan penghubungan data ke destinasi, perubahan format data pada setiap tahap *pipeline*, penyusunan *taxonomy* dan *silver labels*, pembagian *train*, *validation*, dan *locked test* yang aman dari kebocoran, pembangunan *baseline* Keyword dan TF-IDF, serta pelatihan kandidat IndoBERT untuk deteksi aspek dan klasifikasi *polarity*.

5.1. Persiapan Data

Cleaning melakukan normalisasi *Unicode* dan spasi tanpa menghilangkan tanda baca, negasi, *typo*, atau *mixed language* yang penting bagi NLP. *Entity resolution* menghubungkan *review* ke *canonical destination* secara konservatif. Semua *review* bersih memperoleh *destination ID*, kandidat yang belum dapat dipastikan disimpan sebagai *unresolved placeholder* agar tidak dipaksa bergabung.


Entity resolution adalah proses menyatukan penyebutan yang merujuk pada tempat yang sama. Contohnya, nama tempat dapat memiliki perbedaan ejaan pada file *review* dan *metadata*. Pendekatan konservatif berarti sistem lebih memilih menandai hubungan sebagai belum pasti daripada salah menggabungkan dua tempat yang berbeda.



Gambar 5.1 Hasil penghubungan 22.169 *clean reviews* ke *destination ID*.

Sebanyak 16.979 *review* terhubung otomatis karena kecocokannya kuat, 3.901 menggunakan alias yang telah diverifikasi, dan sisanya ditempatkan pada kategori *no-match*, *unresolved*, atau *manual review*. Semua *review* tetap memperoleh ID agar dapat dikelompokkan saat *split*, tetapi *unresolved* ID tidak diklaim sebagai destinasi baru.

Komposisi Canonical Destination



Sebanyak 322 ID berasal dari *metadata anchors* dan dapat dipetakan, sedangkan 66 adalah *unresolved placeholders*. Ini menjelaskan bahwa “388 destinasi” bukan berarti 388 tempat wisata unik yang semuanya sudah diverifikasi, sebagian adalah kelompok aman untuk analisis dan *split*. Setelah aturan kecukupan dan kelayakan diterapkan, 103 destinasi masuk ke keluaran operasional. Perbedaan angka tersebut mencegah destinasi *unresolved* atau tanpa sinyal memadai diperlakukan seolah-olah memiliki prioritas lapangan.

5.2. Contoh Perubahan Bentuk Data

Pipeline menyimpan hasil antara agar setiap tahap dapat diperiksa dan tidak bergantung pada memori notebook. Contoh berikut disederhanakan dan disanitasi dari struktur *artifact* aktual. Artefak tingkat *review*, teks sumber, dan identitas *reviewer* tidak termasuk dalam proyeksi publik.

5.2.1 Bentuk Awal: CSV

CSV adalah file teks berbentuk tabel. Satu baris mewakili satu *review* sumber. Agar contoh tetap mudah dibaca pada halaman portrait, satu baris CSV berikut ditampilkan secara vertikal per *field*.

Tabel 5. 1 Contoh satu record pada CSV sumber

<i>Field / Kolom</i>	<i>Contoh nilai</i>	<i>Peran dalam pipeline</i>
place-name	Pantai Pasir Putih Lumban Bul-bul Balige	Nama tempat yang akan dihubungkan ke destinasi
reviewer-rating	5	Konteks <i>rating</i> dari sumber
review-text	“Pantainya bersih ...”	Teks yang dapat dianalisis dengan NLP

<i>Field / Kolom</i>	<i>Contoh nilai</i>	<i>Peran dalam pipeline</i>
published-at	setahun lalu	Informasi waktu publikasi dari sumber
scraped-at-date	2025-07-29	Tanggal data dikumpulkan

5.2.2 Setelah *Cleaning* dan *Entity Resolution*: Parquet

Parquet adalah format tabel terkompresi. Dibanding CSV, Parquet lebih cepat dibaca oleh *pipeline*, mempertahankan tipe data, dan cocok untuk dataset antara yang besar. Contoh satu row dari `canonical_reviews.parquet`:

```
{
  "review_id": "review_a9dl7694b1521309",
  "source_kind": "wisata",
  "place_name_raw": "Pantai Pasir Putih Lumban Bul-bul Balige",
  "review_text_raw": "Pantainya bersih, hanya saja gerai makanan cenderung agak monoton.",
  "rating": 5.0,
  "destination_id": "dest_wisata_675974ac1b278e",
  "duplicate_group_id": "dup_6d3c085d5f680b65"
}
```

`review_id` memastikan setiap *review* dapat dilacak, `destination_id` menunjukkan tempat hasil *entity resolution*, dan `duplicate_group_id` membantu mencegah teks yang sama bocor ke *split* berbeda. Teks asli dipertahankan pada penyimpanan terkontrol untuk kebutuhan audit, bukan dikirim ke proyeksi publik aplikasi.

5.2.3 Setelah *Annotation*: JSONL

JSONL adalah format dengan satu objek JSON per baris. Format ini cocok untuk label multilabel karena satu *review* dapat memiliki beberapa aspek. Contoh struktur berikut dipersingkat dari `silver-v1.0.0.jsonl`; file aktual tetap terbatas karena memuat teks tingkat *review*:

```
{
  "review_id": "review_000332d077bc2a6e",
  "destination_id": "dest_wisata_0ff99a3eeafd42",
  "text": "pemandangan bagus ... video informasi rusak tak dapat dilihat",
  "labels": [
    {
      "aspect": "scenery",
      "polarity": "positive",
      "severity": null,
      "evidence_text": "pemandangan bagus lihat dari atas.",
      "vote_count": 3,
      "confidence": 1.0
    },
    {
      "aspect": "maintenance",
      "polarity": "negative",
      "severity": "medium",
      "evidence_text": "video informasi ... rusak tak dapat dilihat",
      "vote_count": 3,
      "confidence": 1.0
    }
  ]
},
```

```

    "silver_status": "consensus"
}

```

evidence_text adalah potongan teks yang mendukung label. vote_count: 3 berarti tiga *rule passes* memberi keputusan yang sama, bukan tiga manusia. confidence: 1.0 adalah konsistensi votes, bukan probabilitas terkalibrasi.

5.2.4 Bentuk *Output Inferensi dan Proyeksi Aplikasi*

Setelah TF-IDF dikunci, model dijalankan pada seluruh 12.234 *review* berteks. Proses ini menghasilkan 9.785 prediksi aspek pada 5.942 *review* yang memiliki sedikitnya satu prediksi. Contoh berikut menunjukkan struktur *prediction record* yang disanitasi. Artefak aktual tetap berada pada penyimpanan terbatas:

```

{
  "review_id": "review_a9d17694b1521309",
  "destination_id": "dest_wisata_675974ac1b278e",
  "model_version": "tfidf-lexical-v1.0.4",
  "predictions": [
    {
      "aspect": "cleanliness",
      "aspect_probability": 0.91,
      "polarity": "positive",
      "polarity_probability": null,
      "severity_status": "unavailable_no_supported_model"
    }
  ]
}

```

Prediction record selanjutnya digabungkan berdasarkan destination_id. Sistem menghitung jumlah *mention*, sinyal negatif, *model confidence*, *persistence*, *freshness*, *visitor exposure*, dan kecukupan data. *Severity*, *facility gap*, dan *feasibility* tidak tersedia sehingga tidak dimasukkan sebagai nol atau nilai netral.

Contoh proyeksi ringkasan destinasi yang aman untuk privasi pada *dashboard*:

```

{
  "destination_id": "dest_wisata_675974ac1b278e",
  "model_version": "tfidf-lexical-v1.0.4",
  "data_confidence": "medium",
  "review_coverage": {
    "total_clean_records": 120,
    "textual_records": 76,
    "rating_only_records": 44
  },
  "issues": [
    {
      "aspect": "cleanliness",
      "negative_mentions": 8,
      "support": 14,
      "priority": "monitor",
      "evidence_status": "withheld_pending_privacy_review"
    }
  ],
  "verification_status": "unverified"
}

```

data confidence menjelaskan kecukupan data, bukan keyakinan bahwa kondisi lapangan benar. *support* adalah jumlah dukungan *review*, *priority* menentukan urutan pemeriksaan, dan *verification_status*


menunjukkan bahwa pengelola belum mengonfirmasi sinyal tersebut. Proyeksi publik tidak memuat teks *evidence*, *review_id*, identitas *reviewer*, tautan profil, atau *provenance* baris sumber. Angka pada contoh hanya menjelaskan struktur dan bukan hasil aktual suatu destinasi tertentu.

5.3. Mengapa Hanya 1.320 Review yang Berlabel

Dari 12.234 *review* berteks, dipilih 1.320 *review* untuk *annotation* awal: 120 *review* untuk *pilot*, 1.200 *review* untuk *main sample*, pemilihan mempertimbangkan *destination*, *rating*, panjang teks, jenis sumber, penanda bahasa, *recency*, *candidate complaint*, dan aspek.

Tujuannya adalah memperoleh subset yang cukup beragam dan dapat diaudit, bukan menyatakan bahwa subset tersebut mewakili prevalensi seluruh populasi. Tiga *deterministic rule passes* menghasilkan ***AI-assisted weak-supervision silver labels***. Hasilnya adalah 489 *consensus*, 334 *review_recommended*, dan 497 *no_supported_aspect_records*.


Silver labels bukan *human gold*. *pass_agreement* 0,8827 mengukur konsistensi *rules* dan bukan *inter-annotator agreement* atau *calibrated probability*.



Gambar 5. 2 Jumlah *silver labels* per aspek pada *main sample* 1.200 *review*.

Satu *review* dapat memiliki beberapa aspek, sehingga total batang tidak sama dengan jumlah *review*. Pemandangan, pelayanan staf, transparansi harga, dan kebersihan memiliki *support* terbesar. Jam operasional, keselamatan, kepadatan, dan sampah jauh lebih sedikit. Ketimpangan ini menjadi alasan penggunaan *stratified sampling*, *class weighting*, dan *Macro F1*. Distribusi ini berasal dari *sample* yang sengaja memperbanyak aspek langka, sehingga tidak boleh dianggap sebagai prevalensi seluruh pariwisata Toba.

Distribusi Polarity dan Severity Silver



Gambar 5.3 Distribusi *polarity* dan *severity* pada *main sample*.

Bagian kiri menunjukkan lebih banyak label positif daripada negatif/netral. Bagian kanan hanya menghitung label negatif: *severity* rendah paling banyak, diikuti sedang, sedangkan tinggi relatif sedikit. Gambar ini menjelaskan mengapa *severity* tinggi tidak dapat dinilai hanya dengan *accuracy*; jumlahnya kecil dan setiap *false alert* berpotensi merugikan reputasi destinasi.

5.4. Leakage-Safe Split

Seluruh 1.320 *silver records* dibagi berdasarkan *destination*, bukan secara acak per *review*:

Tabel 5.2 Pembagian *leakage-safe train*, *validation*, dan *locked test*

<i>Split</i>	<i>Records</i>	<i>Destinations</i>
<i>Train</i>	922	181
<i>Validation</i>	196	40
<i>Locked Test</i>	202	40

Proporsi destinasi mendekati 70/15/15, sedangkan jumlah *record* dapat berbeda karena tiap destinasi memiliki volume *review* yang tidak sama. Audit memastikan tidak ada *overlap review ID*, *destination*, *technical duplicate group*, atau *normalized repeated-text group*. Seluruh 14 aspek muncul pada *validation* dan *test*, tetapi *support* beberapa aspek masih kecil, misalnya *opening_hours* hanya memiliki dua contoh pada *test*.

5.5. Baseline Keyword

Keyword baseline menggunakan *lexicon* aspek, konteks lokal, *polarity cues*, *contrast marker*, *intensity*, dan *severity rules*. Model ini transparan dan mudah dijelaskan, tetapi sangat bergantung pada kata yang sudah dikenal.


5.6. Baseline TF-IDF

TF-IDF mengubah teks menjadi pola kata dan potongan karakter. Tiga *representation* diuji hanya pada *validation*.

Tabel 5.3 Perbandingan representasi TF-IDF pada *validation split*

<i>Representation</i>	<i>Validation Macro F1 terhadap silver</i>
<i>Word unigram/bigram</i>	0,7780
<i>Character 3–5 gram</i>	0,7314
<i>Word + character</i>	0,8117

Kombinasi *word* dan *character* memperoleh *Macro F1 validation* tertinggi sehingga dipilih sebagai *baseline TF-IDF final*. *Classifier* menggunakan *One-vs-Rest Logistic Regression* dengan *class weighting*. *Threshold* setiap aspek dipilih hanya dari *validation*.



Gambar 5. 4 Pemilihan TF-IDF *representation* menggunakan *validation split*.

Word memakai pola satu atau dua kata, *char* memakai potongan 3–5 karakter yang membantu menghadapi variasi ejaan, sedangkan *word_char* menggabungkan keduanya. Kombinasi memperoleh *Macro F1 validation* tertinggi, yaitu 0,8117. *Locked test* tidak digunakan untuk memilih *representation* ini.

Konfigurasi gabungan *word* dan *character* tersebut kemudian dibekukan dan digunakan sebagai detektor aspek pada inferensi korpus. Pemilihan ini mengikuti hasil evaluasi, bukan asumsi bahwa model yang lebih kompleks selalu lebih baik.

5.7. Pelatihan Kandidat IndoBERT

Kandidat model lanjutan menggunakan **indobenchmark/indobert-base-p1**. Menggunakan arsitektur BERT dasar 12 lapisan dengan sekitar 124,5 juta parameter, serta BertTokenizer berbasis WordPiece. Pelatihan dilakukan pada Google Colab dengan GPU Tesla T4 menggunakan Python 3.12.13, PyTorch 2.7.1, dan Transformers 4.53.2.


Model aspek menerima satu *review* dan menghasilkan 14 logits multilabel. Pelatihan menggunakan *weighted binary cross-entropy* agar aspek dengan *support* kecil tidak tertutup oleh kelas yang lebih sering. Model *polarity* dibentuk sebagai klasifikasi berbasis aspek: teks masukan memuat aspek yang sedang dinilai dan isi *review*, kemudian model memilih *positive*, *negative*, atau *neutral* menggunakan *weighted cross-entropy*. Pemilihan *checkpoint* hanya menggunakan *validation Macro F1* dan tidak membaca *locked test*.

Tabel 5. 4 Hasil pelatihan IndoBERT pada *silver validation*

Tugas	Epoch pertama <i>Macro F1</i>	Terbaik <i>Macro F1</i>	Best epoch	<i>Validation loss</i>	Waktu <i>Training</i>
Deteksi aspek multilabel	0,2822	0,4012	4	0,7824	100,10 detik
<i>Aspect-</i>	0,6453	0,7044	4	0,6962	126,55 detik


Tugas	Epoch pertama Macro F1	Terbaik Macro F1	Best epoch	Validation loss	Waktu Training
condition					
ed					
polarity					

Kedua tugas meningkat hingga *epoch* keempat. Nilai aspek 0,4012 masih memakai *threshold* sementara 0,50 dan bukan hasil final karena setiap aspek dapat memerlukan batas keputusan berbeda. Nilai *polarity* 0,7044 dihitung pada pasangan aspek yang tersedia dalam *silver validation*. Semua angka pada tabel adalah *silver agreement* di *validation*, bukan performa terhadap *human-gold labels* dan bukan hasil *locked test*.



Gambar 5. 5 Riwayat *loss* dan *validation Macro F1* model aspek IndoBERT.

Kurva menunjukkan *training loss* dan *validation loss* menurun selama empat *epoch*, sementara *validation Macro F1* meningkat dari 0,2822 menjadi 0,4012. Hasil ini mendukung pemilihan *checkpoint epoch* keempat, tetapi belum menentukan *threshold* deteksi final.



Gambar 5. 6 Riwayat *loss* dan *validation Macro F1* model *polarity* IndoBERT.

Validation Macro F1 polarity meningkat dari 0,6453 menjadi 0,7044. *Validation loss* mulai mendatar dan sedikit meningkat pada *epoch* keempat, sedangkan F1 hanya naik tipis dari 0,7039 menjadi 0,7044. Karena itu, penambahan *epoch* belum memiliki dasar yang cukup sebelum dilakukan analisis kesalahan.

Keberhasilan pelatihan, verifikasi hash, dan *reload* luring membuktikan bahwa kandidat IndoBERT dapat direproduksi, tetapi tidak otomatis menjadikannya model produk. Kandidat deteksi aspek IndoBERT tidak dipilih karena hasil *locked silver test* lebih rendah daripada TF-IDF. Kandidat *polarity* IndoBERT juga tidak digunakan pada proyeksi aplikasi karena bobot produksinya tidak tersedia di *workspace* saat inferensi korpus dijalankan; produk menggunakan lexical-polarity-v1 yang diberi versi jelas dan tidak menghasilkan probabilitas.

Model *severity* tidak dilatih. Setiap kelas diwajibkan memiliki sedikitnya 20 contoh *train* dan 5 contoh *validation*, tetapi kelas *high* hanya memiliki 19 contoh *train* dan 6 contoh *validation*. Menurunkan batas hanya untuk menghasilkan *artifact* akan melemahkan metodologi. Oleh sebab itu, SIPATURE belum memiliki hasil atau klaim performa *severity*.

Pada tahap kalibrasi IndoBERT, *temperature scaling* memilih suhu 0,60 hanya dari *validation*. Pemilihan *threshold* per aspek meningkatkan *validation Macro F1* dari 0,4012 menjadi 0,5535 dan *Micro F1* dari 0,4326 menjadi 0,5696. NLL membaik dari 0,4533 menjadi 0,4236, ECE dari 0,2706 menjadi 0,2253, dan Brier Score dari 0,1441 menjadi 0,1388. Setelah model, konfigurasi, suhu, serta *threshold* dibekukan dan dicatat dengan hash, IndoBERT dievaluasi tepat satu kali pada *locked test*.

6. Evaluasi Model

Bagian ini mengevaluasi kemampuan model dalam mendeteksi aspek dan menentukan *polarity* secara terkontrol. Keyword, TF-IDF, dan kandidat IndoBERT dibandingkan pada *locked silver test* yang sama dengan *Macro F1* sebagai metrik utama, dilengkapi *Micro F1*, hasil per aspek, kualitas probabilitas, *latency*, dan analisis kesalahan. Seluruh hasil pada bagian ini menunjukkan kesesuaian terhadap *silver labels*, bukan akurasi terhadap penilaian manusia atau konfirmasi kondisi destinasi di lapangan.

6.1. Protokol


Ketiga model dinilai pada *locked test* yang sama. *Macro F1* dipakai sebagai metrik utama karena semua aspek perlu diperhatikan, termasuk aspek langka. *Micro F1*, *per-aspect F1*, *Precision@Alert*, kualitas probabilitas, dan *latency* dilaporkan sebagai pelengkap. IndoBERT hanya mengakses test setelah kalibrasi validation dan pembekuan konfigurasi selesai.

6.2. Evaluasi Model

Tabel 6. 1 Perbandingan deteksi aspek pada *locked silver test*

<i>Metric</i>	<i>Keyword</i>	<i>TF-IDF word+char</i>	<i>IndoBERT</i>
<i>Macro F1</i>	0,9768	0,7201	0,5247
<i>Micro F1</i>	0,9783	0,8040	0,5241
<i>Latency, ms/review</i>	1,8953	0,1101	8,4693

Keyword memiliki *agreement* paling tinggi terhadap *silver reference*, tetapi hasil ini sangat dipengaruhi oleh penggunaan kosakata *taxonomy* yang juga berkaitan dengan pembentukan *silver labels*. Di antara model yang belajar dari data, TF-IDF mengungguli IndoBERT sebesar 0,1953 *Macro F1* dan 0,2799 *Micro F1*, sekaligus lebih cepat. Kompleksitas model tidak otomatis memberi hasil lebih baik pada 922 contoh *train* dengan label lemah dan distribusi aspek yang timpang. Seluruh angka merupakan *silver agreement*, bukan *human-gold performance*.



Gambar 6. 1 Perbandingan *Macro F1* tiga model terhadap *locked silver test*.

Semakin tinggi batang, semakin sesuai prediksi dengan *silver reference*. *Keyword* tampak sangat tinggi karena menggunakan kosakata yang berkaitan erat dengan pembentukan *silver labels*. TF-IDF menjadi model deteksi aspek yang belajar dari data dengan hasil terbaik pada benchmark ini. Angka ini bukan performa terhadap label manusia.


Keyword memperoleh nilai sangat tinggi karena kosakata *taxonomy* juga berkaitan dengan cara *silver labels* dibentuk. Dengan kata lain, model *Keyword* sangat baik dalam meniru *reference rules*. Hal ini tidak membuktikan bahwa model mampu memahami semua bentuk keluhan nyata.

TF-IDF lebih independen dari *runtime rules*, tetapi tetap belajar dari *silver targets*. Hasil per aspek menunjukkan keterbatasan pada kelas langka:

Tabel 6. 2 Contoh hasil IndoBERT pada aspek dengan *support* terbatas

Aspek	IndoBERT F1	Test support
opening_hours	0,0000	2
crowding	0,5714	6
public_facilities	0,3600	18
safety	0,5000	8
waste	0,8750	9

Nilai F1 harus dibaca bersama *support*. *opening_hours* memiliki F1 nol tetapi hanya dua contoh pada *test*, sehingga estimasinya belum stabil. *waste* memiliki F1 tinggi, namun *support* sembilan juga masih terbatas. Tabel ini mendukung perlunya tambahan *reference* yang lebih kuat dan evaluasi per aspek, bukan hanya satu nilai rata-rata.




Gambar 6. 2 Per-aspect F1 IndoBERT pada *locked silver test*.

IndoBERT paling kuat pada *waste* dan *parking*, sedangkan *opening_hours* memperoleh F1 nol. Perbedaan tersebut tidak boleh dibaca tanpa *support*: *opening_hours* hanya memiliki dua contoh dan *waste* sembilan contoh pada *test*, sehingga sedikit kesalahan sangat memengaruhi skor.

6.3. Calibration, Alert, dan Polarity

Pada *locked test*, IndoBERT memperoleh ECE 0,2021 dan Brier Score 0,1258. Kedua angka mengukur kualitas probabilitas terhadap *silver reference*. *Precision@Alert* keseluruhan adalah 0,5886 pada 175 prediksi, sehingga seluruh *alert* tidak boleh disebut berpresisi tinggi. Dari lima aspek yang mencapai target presisi 0,80 pada *validation*, empat mempertahankannya pada *test*: *parking* 1,0000, *scenery* 0,8889, *staff_service* 1,0000, dan *waste* 1,0000. *cleanliness* turun menjadi 0,7143, menunjukkan bahwa target *validation* bukan jaminan pada data baru.

Kandidat model *polarity* IndoBERT memperoleh *Macro F1* 0,7459 pada 248 pasangan aspek yang tersedia dalam *silver test*. Evaluasi *polarity* menggunakan aspek referensi, bukan aspek hasil prediksi, agar kesalahan deteksi aspek tidak tercampur dengan kualitas klasifikasi positif, negatif, dan netral. Nilai ini merupakan hasil evaluasi kandidat dan bukan performa komponen *polarity* yang digunakan pada proyeksi aplikasi.



Gambar 6.3 *Confusion matrix polarity* IndoBERT pada *locked silver test*.

Kesalahan terbesar adalah 22 contoh positif yang diprediksi netral, disusul 13 contoh negatif yang diprediksi netral. Model *severity* tetap tidak tersedia karena data *train* tidak memenuhi batas minimum *support*; tidak ada metrik *severity* yang diklaim.

7. Hasil dan Pembahasan

Bagian ini merangkum hasil yang telah dicapai dari pengolahan data, evaluasi model, inferensi korpus penuh, agregasi sinyal, hingga integrasi aplikasi SIPATURE. Hasil teknis dibahas bersama keterbatasan yang masih berlaku agar capaian preliminary tidak ditafsirkan sebagai validasi lapangan. Bagian ini juga menjelaskan hubungan antara model dan produk, dampak yang diharapkan bagi pengelola, serta arah pengembangan yang diprioritaskan pada *Final Round*.

7.1. Hasil yang Sudah Tersedia

Tabel 7.1 Ringkasan hasil aktual preliminary SIPATURE

Lapisan	Hasil aktual
Data	22.302 <i>record</i> mentah menjadi 22.169 <i>record</i> bersih
Integrasi	388 <i>canonical IDs</i> : 322 beracuan <i>metadata</i> dan dapat dipetakan, 66 <i>unresolved placeholders</i>
Data belajar	<i>Taxonomy</i> 14 aspek, 1.320 <i>silver records</i> , split 922/196/202 tanpa kebocoran destinasi atau teks berulang terdeteksi
Model	TF-IDF aspek <i>Macro F1</i> 0,7201, IndoBERT aspek 0,5247, kandidat IndoBERT <i>polarity</i> 0,7459 pada <i>locked silver test</i>
Inferensi korpus	12.234 <i>review</i> berteks diproses, 5.942 memiliki prediksi, 9.785 prediksi aspek
Agregasi	1.682 sinyal destinasi-aspek pada 280 destinasi yang memiliki sinyal
Keluaran operasional	103 destinasi dan 210 isu atau kandidat intervensi yang dapat ditindaklanjuti
Produk	Proyeksi agregat terintegrasi pada <i>overview</i> , peta, rapor, antrean, simulator, analyzer, dan <i>fallback</i> peta luring

SIPATURE telah membuktikan satu rantai teknis lengkap dari data mentah, pembersihan, pembentukan data belajar, evaluasi model, inferensi korpus, agregasi, hingga aplikasi. Namun, keluaran operasional masih berupa sinyal triase. Dukungan agregat, status data, penjelasan, dan rekomendasi verifikasi dapat ditampilkan, sedangkan kutipan *evidence*, ID *review*, dan artefak tingkat *reviewer* tetap terbatas sampai pemeriksaan privasi dan ahli selesai. Analyzer pada UI langsung juga masih menggunakan *baseline* leksikal dan tidak mengubah prioritas *batch*.

7.2. Apa yang Belum Boleh Diklaim

Hasil evaluasi model masih menggunakan *silver labels*, bukan label manusia atau konfirmasi kondisi lapangan. Oleh karena itu, *Macro F1* Keyword sebesar 0,9768 tidak dapat disebut sebagai akurasi dunia nyata, sedangkan *Macro F1* TF-IDF sebesar 0,7201 belum membuktikan performa terhadap *human-gold reference*. Kandidat IndoBERT untuk deteksi aspek belum mengungguli TF-IDF pada *locked silver test* dan tidak dipilih sebagai detektor aspek final saat ini. Komponen *polarity* pada aplikasi juga masih berupa *fallback* leksikal, bukan kandidat IndoBERT, serta tidak menghasilkan probabilitas. SIPATURE belum memiliki model atau metrik *severity*, sementara komponen *facility gap* dan *feasibility* juga belum tersedia.

Pada tingkat produk, *priority score* belum divalidasi bersama *stakeholder*. *Evidence correctness*, kesesuaian peringkat, dan penghematan waktu belum diukur terhadap penilaian manusia; *Precision@Alert* yang tersedia masih dihitung terhadap *silver reference*. Aplikasi hanya menggunakan proyeksi agregat yang aman untuk privasi, sedangkan *prediction record*, teks *evidence*, dan provenance tingkat *reviewer* tetap berada pada penyimpanan terbatas. Kualitas *evidence*, relevansi intervensi, dan peringkat juga belum dinilai pada 25 kasus ahli yang telah disiapkan. Selain itu, Analyzer langsung masih menggunakan *baseline* leksikal dan belum merupakan model produksi final.

7.3. Hubungan Model dengan Produk

Benchmark menunjukkan bahwa kombinasi TF-IDF *word* dan *character* lebih kuat daripada kandidat IndoBERT untuk deteksi aspek pada *locked silver test*. Konfigurasi TF-IDF tersebut dibekukan dan digunakan untuk memproses 12.234 *review* berteks. Karena bobot kandidat IndoBERT *polarity* tidak tersedia di *workspace* ketika inferensi korpus dijalankan, *polarity* menggunakan lexical-polarity-v1, yaitu fallback deterministik dan tidak menghasilkan probabilitas.

Inferensi menghasilkan 9.785 prediksi aspek dan agregasi menghasilkan 1.682 sinyal destinasi-aspek. Sistem menerapkan bobot *freshness* dan duplikat, Bayesian smoothing, serta aturan kecukupan data. Bobot prioritas hanya dinormalisasi atas *complaint frequency*, *model confidence*, *persistence*, dan *visitor exposure* yang tersedia. *Severity*, *facility gap*, dan *feasibility* tidak diimputasi.

Proyeksi agregat yang aman untuk privasi telah diintegrasikan ke aplikasi SIPATURE dengan versi model, waktu pembuatan, hash sumber, *taxonomy*, *support*, *data confidence*, rekomendasi verifikasi, serta status komponen yang belum tersedia. Teks ulasan, kutipan *evidence*, *review_id*, identitas *reviewer*, dan provenance baris sumber tetap pada penyimpanan terkontrol.

Alur ini mencegah angka evaluasi bercampur dengan *output* produksi. Data *training* menjawab “apakah model sesuai dengan *reference*?”, sedangkan *full-corpus inference* menjawab “isu apa yang dilaporkan pada seluruh data?”.

7.4. Dampak yang Diharapkan

SIPATURE diharapkan membantu pengelola mengurangi waktu membaca ulasan, menemukan isu yang berulang, dan memulai verifikasi dari masalah yang memiliki dukungan agregat serta kecukupan data memadai. Pemerintah daerah dapat melihat pola lintas destinasi tanpa mengganggu sistem sebagai pengganti inspeksi.

Tabel 7. 2 Indikator dampak pada pilot

Dampak yang diharapkan	Indikator	Cara pengukuran
Mengurangi beban membaca ulasan	Waktu penyelesaian tugas manual dibandingkan tugas berbantuan SIPATURE	Median waktu, rentang antar-kuartil, dan persentase penghematan waktu
Meningkatkan relevansi temuan	Proporsi isu yang dinilai relevan oleh pengelola	Status <i>confirmed</i> , <i>rejected</i> , atau <i>uncertain</i>
Memperbaiki urutan verifikasi	Kesesuaian peringkat SIPATURE dengan urutan buatan pengelola	<i>Ranking agreement</i> dan evaluasi kualitatif
Menjaga keterlacakan	Proporsi sinyal yang didukung kutipan sumber pada audit terkontrol	<i>Evidence correctness rate</i> dan <i>unsupported alert rate</i>
Mengurangi risiko reputasi	Proporsi <i>false alert</i> pada kategori berisiko	Presisi per aspek dan pencatatan alasan penolakan
Mendorong tindak lanjut	Sinyal yang berubah menjadi rencana verifikasi atau intervensi	Jumlah dan proporsi status workflow

Indikator dampak belum diberi angka karena *pilot* pengguna belum dilakukan. SIPATURE tidak mengklaim penghematan waktu, peningkatan kualitas destinasi, atau manfaat ekonomi sebelum tersedia pengukuran pembandingan. Pemeriksaan *evidence* dilakukan pada lingkungan terkontrol agar evaluasi keterlacakan tidak membuka data tingkat *reviewer*.

8. Deklarasi Penggunaan AI

AI generatif digunakan untuk membantu perancangan solusi, pengembangan kode, *debugging*, audit aturan, penyusunan dokumentasi, dan pembuatan narasi laporan. *AI-assisted weak supervision* juga digunakan untuk menghasilkan *silver labels* melalui tiga *deterministic rule passes*.

Penggunaan AI dibatasi secara metodologis dan operasional. *Silver labels* tidak disebut sebagai anotasi manusia atau *gold labels*, sedangkan kesepakatan antar-*AI pass* tidak disebut sebagai *inter-annotator agreement*. Nilai *confidence* berbasis *vote* juga tidak ditafsirkan sebagai probabilitas terkalibrasi. AI tidak digunakan untuk menentukan tindakan lapangan secara otomatis karena hasil sistem hanya berfungsi sebagai sinyal awal yang perlu diperiksa.

Evidence berasal dari kutipan *verbatim* pada ulasan sumber dan tidak dibuat oleh model. Teks serta artefak tingkat *reviewer* tetap berada pada penyimpanan terkontrol sampai pemeriksaan privasi dan ahli selesai. Kode dan *artifact* diperiksa melalui *lint*, *unit test*, *schema validation*, *hash verification*, *model reload*, dan pembacaan hasil untuk mengurangi risiko kesalahan yang berasal dari bantuan AI.

Keputusan operasional tetap memerlukan verifikasi manusia karena ulasan adalah laporan pengguna, bukan konfirmasi kondisi aktual.